



DEPARTAMENTO  
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

# Trabajo Final

## Cascadas de Información en Grafos

---

Redes Sociedad y Economía  
Segundo Cuatrimestre de 2018

Integrante	LU	Correo electrónico
Miguel Nehmad Alché	81/16	mikealche@gmail.com



Facultad de Ciencias Exactas y Naturales  
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

## Resumen

En el presente trabajo práctico, se estudian las cascadas de información de acuerdo al libro *Networks, Crowds, and Markets: Reasoning about a Highly Connected World* de David Easley y Jon Kleinberg. Particularmente, estudiamos el modelo de una urna con bolillas rojas y azules en distintas cantidades. A la vez se expande el modelo lineal en el que cada agente toma decisiones viendo una ventana de las decisiones anteriormente tomadas por otros agentes a un modelo en un grafo, donde cada agente puede ver las decisiones tomadas por sus vecinos. En base a ello, realizamos experimentos para entender mejor el contexto y presentamos los resultados

**Keywords:** Cascadas de Información, Grafos

## Índice

<b>1. Introducción</b>	<b>3</b>
1.1. Motivación . . . . .	3
1.2. Nota Previa . . . . .	3
<b>2. Desarrollo</b>	<b>3</b>
2.1. Modelado . . . . .	3
2.2. Introducción al Programa . . . . .	4
2.2.1. Analizando un output . . . . .	5
<b>3. Experimentación</b>	<b>9</b>
3.1. Experimento 1: Influencia de la probabilidad de ejes en las opiniones . . . . .	9
3.2. Experimento 2: Relación entre número de nodos y opiniones . . . . .	10
3.3. Experimento 3: Diferencia en cascadas entre recorridos BFS y Random . . . . .	12
<b>4. Conclusiones</b>	<b>14</b>

# 1. Introducción

## 1.1. Motivación

Las cascadas de información son un modelo utilizado para formalizar los resultados de posibles decisiones que distintos agentes tomen, teniendo en cuenta el contexto de cada uno. En este trabajo modelaremos a cada agente como un nodo en un grafo y el contexto de cada uno serán sus vecinos. Esto nos servirá para modelar la forma en la que se expanden decisiones cuando la estructura subyacente es un grafo, y cómo la misma estructura influye en las decisiones finales. La elección de esta estructura de red reviste importancia, ya que podemos argumentar que la sociedad en la que vivimos se puede modelar como tal; por ende al estudiar los efectos de la estructura en las decisiones de unos nodos abstractos, también podremos encontrar semejanzas con las decisiones de individuos en la sociedad.

## 1.2. Nota Previa

El presente trabajo puede verse como una expansión del capítulo **16. INFORMATION CASCADES** del libro, específicamente del ejemplo de la urna de bolillas azules y rojas.

Sin embargo aquí expandimos lo que se entiende por *window* o ventana, es decir las decisiones que cada nodo puede ver antes de tomar la suya. Donde antes cada nodo podía ver una cantidad determinada de decisiones de nodos anteriores, ahora cada nodo puede ver las decisiones anteriormente tomadas solo por nodos que sean sus vecinos.

# 2. Desarrollo

## 2.1. Modelado

El modelo general es el siguiente:

Existe una urna que contiene bolillas azules y rojas. Las cantidades de cada una son  $2/3$  y  $1/3$  sin importar cual corresponde a cual.

En el experimento planteado en el libro, la urna estaba frente a un grupo de estudiantes que intentarían adivinar si esta era mayoritariamente roja o azul. Para ello, los estudiantes podrían ir extrayendo uno por uno una bolilla de la urna —sin enseñarla al resto de la clase— y luego comunicar a todos su creencia sobre qué color era el mayoritario. (Easley, David y Kleinberg, Jones, 486)

Con este experimento, se entiende que cada alumno tiene conocimiento de todas las decisiones de los alumnos que extrajeron una bolilla antes que él.

En este trabajo práctico planteamos el estudio de una expansión de este punto. Queremos estudiar qué sucede cuando los alumnos no tienen conocimiento de *todas* las decisiones anteriores sino solamente de algunas específicas, digamos solo las de sus *amigos*

En función de eso, para facilitar el trabajo comenzaremos por cambiar los nombres: reemplazamos a la clase de alumnos por un grafo  $G = (V, E)$ , y a los alumnos de la misma por los nodos del mismo. De esta manera ganamos el concepto de *vecino*. Un nodo  $v$  es vecino de otro  $w$  si existe un enlace de  $v$  a  $w$ , es decir si  $(v, w) \in E$

Entonces son ahora los nodos quienes intentarán decidir si la urna es mayoritariamente compuesta

por bolillas azules o bolillas rojas.

Pero ahora, cada nodo podrá ver solamente las decisiones —no la extracciones— de sus **vecinos** (que ya hayan decidido).

En base a eso y a su propia extracción, él mismo deberá tomar una decisión. Respecto la forma en la que la decisión es tomada, modelamos a los nodos como agentes racionales que actúan de manera tal de maximizar la probabilidad de acertar.

En este sentido, los agentes decidirán azul o rojo según cual de ambas opciones sea la que aparezca con mayor frecuencia en lo que cada cada agente puede ver (las decisiones de sus vecinos y su propia extracción). Esta forma de decidir es racional, la intuición de ello es que una urna digamos mayoritariamente azul —sin pérdida de generalidad— hará que una mayor cantidad de extracciones —y *en principio* decisiones— sean azules.

Sin embargo, esta forma de tomar decisiones (en la que un nodo utiliza la decisión y no la extracción de sus vecinos) no tiene en cuenta el hecho de que pueden estar sucediendo cascadas.

Llamaremos cascada a un proceso en el cual las extracciones individuales de los nodos no influyen en su decisión final; esto se dará debido a que las decisiones de sus vecinos estarán inclinadas hacia una de las opciones y la propia extracción no logra inclinar el conteo de decisiones hacia el color extraído.

Más específicamente la extracción de un nodo, no influirá en su decisión, cuando la diferencia entre las decisiones de sus vecinos sea mayor a 2.

Respecto al orden en el que se toman las decisiones, estudiamos 2 ordenes distintos: el primero completamente aleatorio; el segundo un orden BFS a partir siempre del nodo 0

**Nos interesará estudiar qué efectos produce la estructura del grafo subyacente y el orden en que se toman las decisiones en las cascadas que se producen**

## 2.2. Introducción al Programa

El programa para modelar el trabajo se realizó en Node.js, para correrlo debe tenerse instalado Node.js versión 6+ (<https://nodejs.org/es/>).

Para correrlo se debe llamar al archivo index.js con node. Ejecutando desde la consola

```
node index.js
```

El programa acepta los siguientes argumentos que se pasan en orden, no con una flag.

**Nombre del archivo donde guardar los resultados**, default: ./results.csv

**Probabilidad de enlace entre dos nodos**, default: 0.2 (solo afecta cuando se utiliza tipo de grafo 'network')

**No Generar Logs**, (true — false) default: false

**Numero de nodos**, default: 20

**Nombre del archivo donde guardar el grafo resultante para visualizarlo**, default: ./graphInfo

**Tipo de grafo**, (line — network), default: network (line modelaria el caso propuesto en el libro donde cada *alumno* podía conocer todas las decisiones anteriormente tomadas, network modela el caso donde cada nodo solo puede ver las decisiones de sus vecinos que ya hayan decidido )

**Modo de exploración**, (bfs — random) default: bfs (solo afecta cuando se utiliza tipo de grafo 'network')

Por ejemplo si se ejecuta

```
node index.js ./results.csv 0.05 true 500 ./graphInfo network random
```

Se ejecutará el programa sobre un grafo red de 500 nodos con posibilidad de eje entre cualquiera de 5 %, que se explorará de modo aleatorio y los resultados se guardarán en `./results.csv`, mientras que el grafo se guardará en `./graphInfo`

### 2.2.1. Analizando un output

En esta sección analizaremos el sentido de un output del programa ante un input ejemplo.

Supongamos que se ejecuta el programa sobre un grafo en forma de red de 15 nodos con probabilidad de eje entre un par de nodos de 60 %. A la vez queremos que las decisiones se tomen con orden BFS. Finalmente queremos guardar los resultados estadísticos en `./results.csv` y el grafo con las decisiones de cada nodo resultante en `./graphInfo`

Entonces ejecutamos:

```
!node index.js ./results.csv 0.6 false 15 ./graphInfo network bfs
```

Un posible output es

```
BLUE URN
Using Network Graph
Node : 0 sees blue
Looking at his neighbours sees {}
mantained his decision:  blue
Node 0 decides:  blue

BFS queue:  [ 7, 12, 13 ]
Node : 7 sees red
Looking at his neighbours sees { blue: 1 }
mantained his decision:  red
Node 7 decides:  red

BFS queue:  [ 12, 13, 3, 4, 5, 6, 8, 9, 11 ]
Node : 12 sees blue
Looking at his neighbours sees { blue: 1 }
mantained his decision:  blue
Node 12 decides:  blue

BFS queue:  [ 13, 3, 4, 5, 6, 8, 9, 11, 2, 10 ]
Node : 13 sees red
Looking at his neighbours sees { blue: 2 }
it has been influenced towards:  blue
Node 13 decides:  blue
```

BFS queue: [ 3, 4, 5, 6, 8, 9, 11, 2, 10, 14 ]  
Node : 3 sees red  
Looking at his neighbours sees { red: 1, blue: 2 }  
maintained his decision: red  
Node 3 decides: red

BFS queue: [ 4, 5, 6, 8, 9, 11, 2, 10, 14 ]  
Node : 4 sees red  
Looking at his neighbours sees { red: 1, blue: 1 }  
maintained his decision: red  
Node 4 decides: red

BFS queue: [ 5, 6, 8, 9, 11, 2, 10, 14 ]  
Node : 5 sees blue  
Looking at his neighbours sees { red: 1 }  
maintained his decision: blue  
Node 5 decides: blue

BFS queue: [ 6, 8, 9, 11, 2, 10, 14 ]  
Node : 6 sees blue  
Looking at his neighbours sees { red: 3 }  
it has been influenced towards: red  
Node 6 decides: red

BFS queue: [ 8, 9, 11, 2, 10, 14 ]  
Node : 8 sees blue  
Looking at his neighbours sees { red: 3 }  
it has been influenced towards: red  
Node 8 decides: red

BFS queue: [ 9, 11, 2, 10, 14 ]  
Node : 9 sees red  
Looking at his neighbours sees { red: 3, blue: 1 }  
maintained his decision: red  
Node 9 decides: red

BFS queue: [ 11, 2, 10, 14 ]  
Node : 11 sees blue  
Looking at his neighbours sees { blue: 2, red: 2 }  
maintained his decision: blue  
Node 11 decides: blue

BFS queue: [ 2, 10, 14, 1 ]  
Node : 2 sees red  
Looking at his neighbours sees { red: 4, blue: 3 }  
maintained his decision: red  
Node 2 decides: red

BFS queue: [ 10, 14, 1 ]  
Node : 10 sees red  
Looking at his neighbours sees { red: 4, blue: 2 }  
maintained his decision: red  
Node 10 decides: red

```
BFS queue: [ 14, 1 ]
Node : 14 sees blue
Looking at his neighbours sees { red: 5, blue: 3 }
it has been influenced towards: red
Node 14 decides: red
```

```
BFS queue: [ 1 ]
Node : 1 sees blue
Looking at his neighbours sees { red: 2, blue: 1 }
maintained his decision: blue
Node 1 decides: blue
```

\*\*\*\*\* Statistics Summary \*\*\*\*\*

```
Influencing indexes for node 0 : []
Influencing indexes for node 1 : [ 2, 11, 14 ]
Influencing indexes for node 2 : [ 3, 4, 5, 6, 8, 11, 12 ]
Influencing indexes for node 3 : [ 7, 12, 13 ]
Influencing indexes for node 4 : [ 7, 12 ]
Influencing indexes for node 5 : [ 7 ]
Influencing indexes for node 6 : [ 3, 4, 7 ]
Influencing indexes for node 7 : [ 0 ]
Influencing indexes for node 8 : [ 4, 6, 7 ]
Influencing indexes for node 9 : [ 4, 5, 6, 7 ]
Influencing indexes for node 10 : [ 2, 3, 4, 9, 12, 13 ]
Influencing indexes for node 11 : [ 5, 7, 8, 13 ]
Influencing indexes for node 12 : [ 0 ]
Influencing indexes for node 13 : [ 0, 12 ]
Influencing indexes for node 14 : [ 2, 3, 5, 8, 9, 10, 11, 13 ]
```

```
Number of nodes whose opinion didnt matter: 10
Number of nodes who changed opinion towards the crowd: 4
```

Lo que sucedió fue lo siguiente:

La urna es mayoritariamente azul.

Comienza el nodo 0 y realiza una extracción en la que ve una bolilla azul. Como no tiene vecinos que hayan decidido pues él es el primero, decide azul.

Luego agrega a la cola BFS a los nodos 7, 12 y 13

El nodo 7 (el primero en la cola), extrae una bolilla roja. Viendo a sus vecinos, observa que el nodo 0 (quien lo agregó a la cola BFS) decidió azul. Por ende el nodo 7 termina decidiendo rojo también.

A la vez, el nodo 7 agregará a la cola BFS los nodos 3, 4, 5, 6, 8, 9 y 11

Luego sigue el nodo 12. El nodo 12 extrae una bolilla azul. Observando a sus vecinos ve la decisión azul (la del nodo 0 que lo agregó a la cola BFS). Por ende el nodo 12 decide azul.

El nodo 12 a su vez agregará a la cola BFS los nodos 2 y 10

El nodo 13 extrae rojo. Como 13 vio dos decisiones azules y el extrajo rojo, el decidirá azul. Diremos entonces que él fue influenciado hacia el color azul. Luego ocurrió una cascada.

Su decisión sumará 1 a "Number of nodes whose opinion didn't matter" pues su extracción no influyó en su decisión y también sumará otro punto a "Number of nodes who changed opinion towards the crowd" pues originalmente el había visto rojo, pero decidió azul.

Estas dos medidas, podrán verse al final del output. En este caso

```
Number of nodes whose opinion didnt matter: 10
Number of nodes who changed opinion towards the crowd: 4
```


De manera similar se sucederán el resto de las decisiones.

Para más detalle, correr la jupyter notebook llamada Visualizacion. Para ello habrá que tener instalado jupyter notebook y correr desde el directorio donde se haya clonado el proyecto

```
jupyter notebook
```

Luego se abrirá un explorador en el que habrá que seleccionar la notebook Visualizacion

En este caso el grafo resultante es el siguiente:



(a) Grafo Resultante

Aquí el código de colores significa lo siguiente:

**Rojo fuerte:** el nodo extrajo una bolilla roja y decidió rojo en base a ello

**Azul fuerte:** el nodo extrajo una bolilla azul y decidió azul en base a ello

**Rosa:** el nodo extrajo una bolilla de cualquier color y decidió rojo en base a las decisiones de sus vecinos

**Celeste:** el nodo extrajo una bolilla de cualquier color y decidió azul en base a las decisiones de sus vecinos



### 3. Experimentación

#### 3.1. Experimento 1: Influencia de la probabilidad de ejes en las opiniones

En este experimento queremos ver cómo afecta a las cascadas una mayor probabilidad de ejes entre nodos.


La hipótesis es que a mayor cantidad de ejes, mayor es la probabilidad de que la diferencia entre decisiones azules y rojas de los vecinos supere el umbral de 2, y por tanto se produzca una cascada.

Si bien en cada corrida del programa la urna puede ser mayoritariamente roja o azul, esto no afecta a los resultados ya que las cascadas se cuentan independientemente del color hacia el cual se producen. Tampoco se diferencia entre cascadas correctas e incorrectas, entendiendo a las primeras como las cascadas que se producen hacia el color del cual es mayoritario la urna y de manera inversa a las segundas.

Lo que sí se diferencia es cuando un nodo es influenciado por una cascada hacia el color contrario del cual extrajo, de cuando es influenciado hacia el mismo color de su extracción. En el primer caso diremos que la opinión del nodo fue **cambiada** por la cascada. Mientras que en el segundo diremos que la opinión fue **afectada** por la misma.

Para realizar el experimento elegimos los siguientes valores: Tomamos 50 nodos y probabilidad de ejes de 0 al 100% con intervalo de 10%. Para cada intervalo realizamos 10 iteraciones y tomamos el promedio. Siempre que no se mencione, se puede asumir que se utilizaron las opciones por defecto de grafo tipo network y recorrido bfs.

El resultado es el siguiente:



(a) Opiniones influenciadas en función de probabilidad de ejes

Podemos ver que tal como se supuso en la hipótesis, una mayor cantidad de ejes afecta positivamente a la cantidad de cascadas que suceden.

Claramente las opiniones cambiadas por la cascada son menores a las afectadas, pues existe el caso

donde la cascada lleve a decidir el mismo color que un nodo extraído de la urna, el cual no incrementa las opiniones cambiadas, pero sí las afectadas.

### 3.2. Experimento 2: Relación entre número de nodos y opiniones


Para este experimento, tomamos una probabilidad de ejes fija y analizamos si incrementar la cantidad de nodos, incrementa la cantidad de opiniones afectadas y cambiadas por las cascadas.

En un principio es parece natural suponer que sí; que la relación será creciente, pues a mayor cantidad de nodos mayor posibilidad de que alguno de ellos tenga su decisión afectada o cambiada por sus vecinos.

Sin embargo, lo interesante será ver si esa relación es verdaderamente *lineal*.

La hipótesis es que no lo será: que el porcentaje de nodos cuyas opiniones son afectadas o cambiadas por una cascada debería incrementarse a medida que se incremente la cantidad de nodos. Esto se intuye debido a que no solo cada nodo contribuye con su propia opinión a ser cambiada por la cascada, sino que también se constituye como un nodo que puede influenciar y afectar las opiniones de sus vecinos.

Para el experimento, tomamos probabilidad de ejes de 30 % e incrementamos la cantidad de nodos desde 50 hasta 500 con intervalos de 50. El resultado es el siguiente:



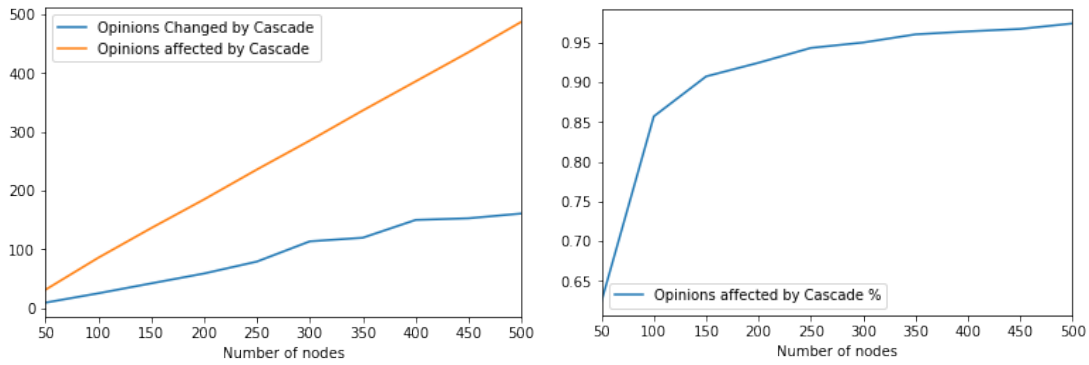
(a) Opiniones afectadas y cambiadas en función de la cantidad de nodos (b) Porcentaje de opiniones afectadas en función de la cantidad de nodos

Figura 3: Resultados para probabilidad de eje entre nodos de 30 %

En efecto podemos observar que si bien al analizar el primer gráfico la relación de opiniones afectadas con la cantidad de nodos parece lineal, al analizar el gráfico de porcentajes se vé que el mismo se va incrementando.

Profundicemos el análisis probando con otros porcentajes de ejes.


Comencemos con uno más bajo que el anterior, probemos 10 % de probabilidad de ejes. El resto de los parámetros se mantienen del experimento anterior. Los resultados son los siguientes:



(a) Opiniones afectadas y cambiadas en función de la cantidad de nodos (b) Porcentaje de opiniones afectadas en función de la cantidad de nodos

Figura 4: Resultados para probabilidad de eje entre nodos de 10 %

Ahora probemos con un porcentaje de ejes mayor al primero de todos, probemos 80 %. El resto de los parámetros se mantienen del experimento anterior. Los resultados son los siguientes:



(a) Opiniones afectadas y cambiadas en función de la cantidad de nodos (b) Porcentaje de opiniones afectadas en función de la cantidad de nodos

Figura 5: Resultados para probabilidad de eje entre nodos de 80 %

Analizando los gráficos b de las figuras 3, 4 y 5 podemos concluir que la relación no es lineal. En efecto en todos ellos el porcentaje de opiniones afectadas va en aumento a manera que se incrementa la cantidad de nodos en el grafo. Entendemos que el motivo de esto es que cada nodo afecta al conteo de una manera doble: como nodo que puede tener su opinión afectada y como nodo que puede afectar la opinión de sus vecinos.

También podemos preguntarnos en qué varía cambiar la probabilidad de ejes. En la figura 4.b podemos ver que el porcentaje de opiniones afectadas para 50 nodos está cerca del 65 %, mientras que en la figura 5.b vemos que para la misma cantidad de nodos el porcentaje opiniones afectadas ronda el 95 %. Pero en ambos casos (también en la figura 3.b) vemos que al ir aumentando la cantidad de nodos el porcentaje de opiniones afectadas alcanza un mismo techo cercano al 100 %.

Por lo cual podemos afirmar que la probabilidad de ejes afecta de manera relativa a las opiniones afectadas por las cascadas según la cantidad de nodos presentes en el grafo. Esto tiene sentido, ya que lo que verdaderamente afecta la probabilidad de que un nodo tenga su opinión afectada por la cascada es **su cantidad de vecinos** y esto no es más que el producto de la probabilidad de ejes por la cantidad de nodos en el grafo.

A mayor cantidad de vecinos, mayor probabilidad de que las decisiones de los mismos se diferencien por un valor mayor a 2, ya que siguiendo la ley de los grandes números, el conteo resultante de una gran cantidad de extracciones debería aproximarse a la distribución real de la urna que es de  $1/3$  a  $2/3$ . Esto sería sin tener en cuenta la existencia de cascadas anteriores entre los vecinos en sí, es decir estaríamos viendo el caso donde los nodos anteriores deciden el mismo color extraído. En el caso de que existan cascadas anteriores entre los vecinos afirmamos que el efecto será aún más pronunciado pues las cascadas tienden a que todas las decisiones tomen un único color, incrementando aún más la diferencia en decisiones que un nodo puede ver. Sería muy poco probable que justo existan 2 cascadas de colores opuestos que se contrarresten de manera tal que la diferencia entre cantidad de decisiones para cada color que un nodo pueda ver sea menor a 2.

### 3.3. Experimento 3: Diferencia en cascadas entre recorridos BFS y Random

En este experimento queremos analizar las diferencias en las opiniones afectadas o cambiadas por cascadas para recorridos BFS o random (aleatorio), para grafos de distinto tamaño.

La hipótesis previa es que se espera que el recorrido BFS produzca mayor cantidad de cascadas, pues garantiza que para todo nodo (excepto el primero) existe algún otro vecino que ya habrá decidido y podrá afectar su decisión.

Para ello tomamos una probabilidad de eje entre nodos fija de 0.1 % y fuimos variando la cantidad de nodos desde 500 hasta 6000 con intervalos de 500. Para cada caso, tomamos el promedio de 5 repeticiones para disminuir la varianza.

El resultado es el siguiente:

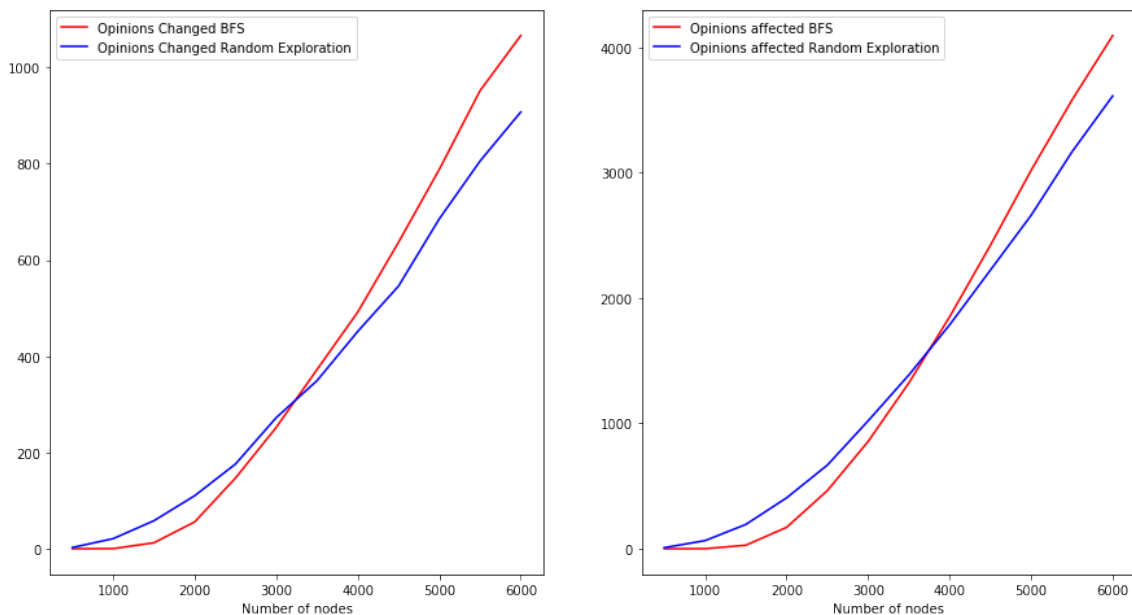


Figura 6: Opiniones afectadas y cambiadas en función de la cantidad de nodos para exploraciones Random y BFS

Sorprendentemente, parece haber un punto de inflexión en los gráficos. Una cantidad de nodos donde la exploración BFS comienza a producir más cascadas que la exploración random. Es decir, BFS no comienza siendo el mayor productor de cascadas para una cantidad pequeña de nodos.

¿a qué se debe este comportamiento sumamente interesante?

Cuando se mantiene la probabilidad de ejes fija, aumentar la cantidad de nodos, también aumenta la cantidad total promedio de vecinos de cada nodo.

Parecería ser que BFS recién comienza a tener efecto positivo en la cantidad de cascadas que se producen una vez que se supera cierto umbral de conectividad en el grafo.

Esto hace sentido: si se realizan recorridos BFS en grafos débilmente conexos (supongamos 1 solo enlace por nodo) podemos asegurar que *no* habrá cascadas, ya que mirar la decisión de un solo vecino no alcanza para generar una cascada.

Sin embargo, el resultado de este experimento demanda un análisis más fino.

Probemos estudiar el impacto en las cascadas entre exploraciones BFS y random en función de la probabilidad de ejes.

Para ello fijamos la cantidad de nodos en 1000, las repeticiones en 60, y la probabilidad de ejes de 10 % a 100 % con intervalos de 10 %. El grafo es de tipo *network*.

El resultado es el siguiente




Figura 7: Opiniones afectadas y cambiadas en función de la probabilidad de ejes para exploraciones Random y BFS

Analizando el gráfico derecho de la figura 7 se puede ver el recorrido random no fomenta tantas cascadas como BFS, para valores bajos de probabilidad de ejes, pero parece alcanzarlo para los valores más altos.

Se podría suponer que esto se debe a que para valores bajos de probabilidad de ejes, el hecho de asegurar que todos los nodos puedan ver al menos una decisión anterior (salvo el primer nodo, claro está) cobra mayor importancia.

A la vez mirando el caso opuesto, a mayor probabilidad de eje, más se asemejará un recorrido random a un recorrido BFS; pues si suponemos el caso extremo, en una clique completa todo recorrido random se puede ver como un recorrido BFS de un solo nivel.

Por lo tanto podemos utilizar el gráfico derecho de la figura 7 para explicar el parte del comportamiento inesperado del experimento anterior:

El efecto positivo de BFS sobre las cascadas es más notorio cuanto menor sea la conectividad del grafo. En la gráfico derecho de la figura 6, al aumentar la cantidad de nodos pero mantener constante la probabilidad de ejes, la conectividad del grafo disminuye. Por tanto se explica por qué al aumentar la cantidad de nodos se comienza a diferenciar el efecto positivo de BFS sobre la cantidad de opiniones afectadas, es decir la cantidad de cascadas.

## 4. Conclusiones

Del trabajo realizado podemos extraer las siguientes conclusiones.

El modelado de eventos en una red es una tarea compleja.

Principalmente por el inmenso espacio de combinaciones posibles al intentar realizar experimentos.

El tamaño de los modelos impide en muchos casos que la intuición humana logre predicciones correctas, por lo cual el trabajo científico requiere gran rigurosidad y minuciosidad.

Sin embargo, es sin duda una área de estudio apasionante.

Durante la realización de este trabajo, me introduje en el análisis de teoría de grafos espectral, que involucra establecer relaciones entre los autovalores y autovectores de la matriz de adyacencia del grafo y las propiedades del grafo en sí.

Lamentablemente, en este trabajo práctico no se ve reflejada esa investigación, pero afectó de manera paralela toda esta búsqueda.

Respecto de las conclusiones de los experimentos: En los dos primeros se puede argumentar que la riqueza de los mismo radica tal vez en la precisión de los números para casos precisos. Pues la tendencia general de los resultados coincide con la intuición mayormente.

Sin embargo, en el tercer experimento, los resultados se alejaron de la intuición e hipótesis previa. Lo cual aduce que el estudio de procesos en cascadas en grafos encierra complejidades ocultas que demandan una profundización del estudio.